

Visualización de datos

Dataset a emplear dataset = household_power_consumption

2. Cargando el dataset

Este archivo usa ; como separador y tiene valores faltantes marcados como ?. Cópialo en tu notebook:

```
In [13]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Configuración visual global – ponla siempre al inicio
plt.rcParams['figure.figsize'] = (12, 5)
plt.rcParams['font.size'] = 11
sns.set_theme(style='whitegrid')

# Cargar el dataset
df = pd.read_csv(
    '../datasets/household_power_consumption.txt',
    sep=';',
    na_values='?',          # Los '?' se convierten en NaN automáticamente
    low_memory=False
)

# Exploración inicial – siempre primero
print("-----")
print(df.shape)
print("-----")
print(df.head())
print("-----")
print(df.info())
print("-----")
print(df.isnull().sum())
```

(2075259, 9)

	Date	Time	Global_active_power	Global_reactive_power	Voltage	\
0	16/12/2006	17:24:00	4.216	0.418	234.84	
1	16/12/2006	17:25:00	5.360	0.436	233.63	
2	16/12/2006	17:26:00	5.374	0.498	233.29	
3	16/12/2006	17:27:00	5.388	0.502	233.74	
4	16/12/2006	17:28:00	3.666	0.528	235.68	

	Global_intensity	Sub_metering_1	Sub_metering_2	Sub_metering_3
0	18.4	0.0	1.0	17.0
1	23.0	0.0	1.0	16.0
2	23.0	0.0	2.0	17.0
3	23.0	0.0	1.0	17.0
4	15.8	0.0	1.0	17.0

<class 'pandas.DataFrame'>
RangeIndex: 2075259 entries, 0 to 2075258
Data columns (total 9 columns):

#	Column	Dtype
0	Date	str
1	Time	str
2	Global_active_power	float64
3	Global_reactive_power	float64
4	Voltage	float64
5	Global_intensity	float64
6	Sub_metering_1	float64
7	Sub_metering_2	float64
8	Sub_metering_3	float64

dtypes: float64(7), str(2)

memory usage: 142.5 MB

None

Date 0
Time 0
Global_active_power 25979
Global_reactive_power 25979
Voltage 25979
Global_intensity 25979
Sub_metering_1 25979
Sub_metering_2 25979
Sub_metering_3 25979
dtype: int64

3. Limpieza mínima necesaria

```
In [14]: # Combinar Date y Time en un solo datetime
df['Datetime'] = pd.to_datetime(df['Date'] + ' ' + df['Time'],format='%d/%m/%Y %H:%M:%S')

# Poner Datetime como índice – clave para series temporales
df.set_index('Datetime', inplace=True)
df.drop(columns=['Date', 'Time'], inplace=True)

# Eliminar filas con nulos en la columna principal
df.dropna(subset=['Global_active_power'], inplace=True)

# Convertir columnas a numérico por seguridad
cols = ['Global_active_power', 'Global_reactive_power',
        'Voltage', 'Global_intensity',
        'Sub_metering_1', 'Sub_metering_2', 'Sub_metering_3']
```

```
df[cols] = df[cols].apply(pd.to_numeric, errors='coerce')

print("-----")
print(df.shape)
print("-----")
print(df.head())
```

```
-----
(2049280, 7)
-----
```

	Global_active_power	Global_reactive_power	Voltage	\
Datetime				
2006-12-16 17:24:00	4.216	0.418	234.84	
2006-12-16 17:25:00	5.360	0.436	233.63	
2006-12-16 17:26:00	5.374	0.498	233.29	
2006-12-16 17:27:00	5.388	0.502	233.74	
2006-12-16 17:28:00	3.666	0.528	235.68	

	Global_intensity	Sub_metering_1	Sub_metering_2	\
Datetime				
2006-12-16 17:24:00	18.4	0.0	1.0	
2006-12-16 17:25:00	23.0	0.0	1.0	
2006-12-16 17:26:00	23.0	0.0	2.0	
2006-12-16 17:27:00	23.0	0.0	1.0	
2006-12-16 17:28:00	15.8	0.0	1.0	

	Sub_metering_3
Datetime	
2006-12-16 17:24:00	17.0
2006-12-16 17:25:00	16.0
2006-12-16 17:26:00	17.0
2006-12-16 17:27:00	17.0
2006-12-16 17:28:00	17.0

4. Matplotlib — el motor de visualización

Matplotlib es la base de casi toda visualización en Python. Seaborn está construido sobre él. El concepto central es la figura con ejes:


Figure → el lienzo completo

Axes → el área donde vive un gráfico dentro del lienzo


Puedes tener múltiples Axes dentro de una Figure, lo que te permite comparar gráficos lado a lado.

```
In [15]: # Gráfico 1 – Consumo activo a lo largo del tiempo (muestra 1 semana)
semana = df['Global_active_power']['2007-01-01':'2007-01-07']


fig, ax = plt.subplots()
ax.plot(semana, color='#2E86AB', linewidth=0.8, alpha=0.9)
ax.set_title('Consumo eléctrico activo – primera semana de enero 2007')
ax.set_xlabel('Fecha y hora')
ax.set_ylabel('Potencia activa (kW)')
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```



```
In [16]: # Gráfico 2 – Distribución del consumo (histograma)
fig, ax = plt.subplots()
ax.hist(df['Global_active_power'].dropna(),
        bins=60, color='#2E86AB', edgecolor='white', alpha=0.85)
ax.set_title('Distribución del consumo activo global')
ax.set_xlabel('Potencia activa (kW)')
ax.set_ylabel('Frecuencia')
plt.tight_layout()
plt.show()
```




```
In [17]: # Gráfico 2 – Distribución del consumo (histograma)
fig, ax = plt.subplots()
ax.hist(df['Sub_metering_1'].dropna(),
        bins=60, color='#2E86AB', edgecolor='white', alpha=0.85)
ax.set_title('Distribución de Sub_metering_1')
ax.set_xlabel('Potencia activa (kW)')
ax.set_ylabel('Frecuencia')
plt.tight_layout()
plt.show()
```




In [18]: *# Gráfico 1 – Consumo activo a lo largo del tiempo (muestra 1 semana)*
 semana = df['Sub_metering_1']['2007-01-01':'2007-01-07']

```
fig, ax = plt.subplots()
ax.plot(semana, color='#2E86AB', linewidth=0.8, alpha=0.9)
ax.set_title('Consumo Sub_metering_1 – primera semana de enero 2007')
ax.set_xlabel('Fecha y hora')
ax.set_ylabel('Potencia activa (kW)')
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```




In [19]: *# Gráfico 2 – Distribución del consumo (histograma)*
 fig, ax = plt.subplots()
 ax.hist(df['Sub_metering_2'].dropna(),
 bins=60, color='#2E86AB', edgecolor='white', alpha=0.85)
 ax.set_title('Distribución de Sub_metering_2')
 ax.set_xlabel('Potencia activa (kW)')
 ax.set_ylabel('Frecuencia')
 plt.tight_layout()
 plt.show()




```
In [20]: # Gráfico 1 – Consumo activo a lo largo del tiempo (muestra 1 semana)
semana = df['Sub_metering_2']['2007-01-01':'2007-01-07']
```

```
fig, ax = plt.subplots()
ax.plot(semana, color='#2E86AB', linewidth=0.8, alpha=0.9)
ax.set_title('Consumo Sub_metering_2 – primera semana de enero 2007')
ax.set_xlabel('Fecha y hora')
ax.set_ylabel('Potencia activa (kW)')
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```




```
In [21]: # Gráfico 2 – Distribución del consumo (histograma)
fig, ax = plt.subplots()
ax.hist(df['Sub_metering_3'].dropna(),
        bins=60, color='#2E86AB', edgecolor='white', alpha=0.85)
ax.set_title('Distribución de Sub_metering_3')
ax.set_xlabel('Potencia activa (kW)')
ax.set_ylabel('Frecuencia')
plt.tight_layout()
plt.show()
```



```
In [22]: # Gráfico 1 – Consumo activo a lo largo del tiempo (muestra 1 semana)
semana = df['Sub_metering_3']['2007-01-01':'2007-01-07']

fig, ax = plt.subplots()
ax.plot(semana, color='#2E86AB', linewidth=0.8, alpha=0.9)
ax.set_title('Consumo Sub_metering_3 – primera semana de enero 2007')
ax.set_xlabel('Fecha y hora')
ax.set_ylabel('Potencia activa (kW)')
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```




5. Seaborn — estadística visual con menos código

Seaborn está diseñado para gráficos estadísticos. Con menos líneas de código obtienes más información.

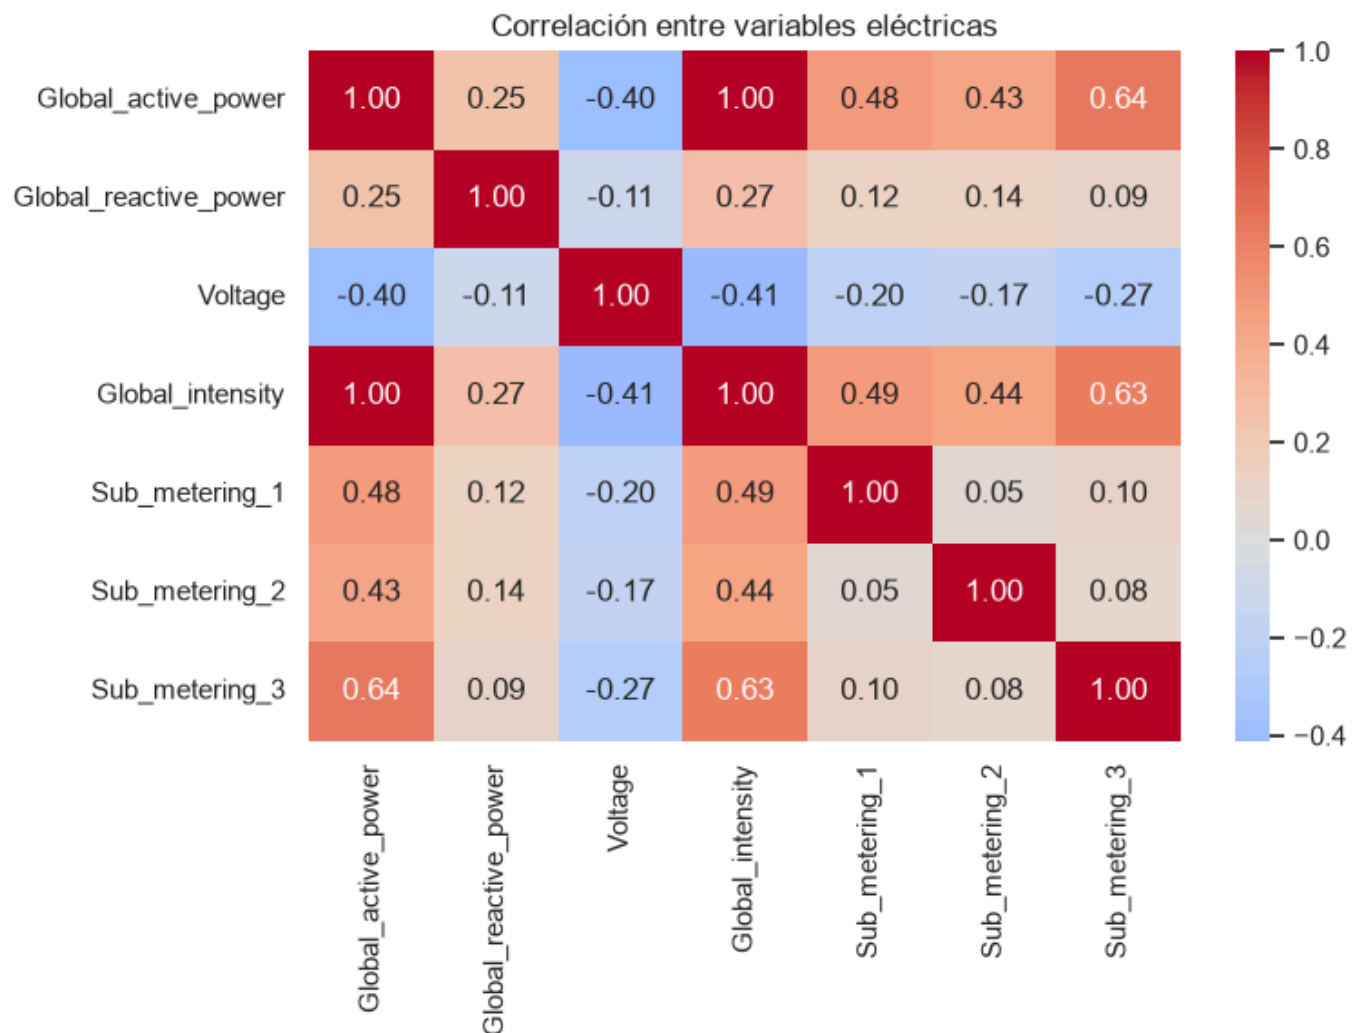
```
In [23]: # Gráfico 3 – Consumo promedio por hora del día
df['hora'] = df.index.hour
consumo_por_hora = df.groupby('hora')['Global_active_power'].mean().reset_index()

fig, ax = plt.subplots()
sns.barplot(data=consumo_por_hora,
            x='hora', y='Global_active_power',
            color='#2E86AB', ax=ax)
ax.set_title('Consumo promedio por hora del día')
ax.set_xlabel('Hora')
```

```
ax.set_ylabel('Potencia activa promedio (kW)')
plt.tight_layout()
plt.show()
```




```
In [24]: # Gráfico 4 – Correlación entre variables (heatmap)
fig, ax = plt.subplots(figsize=(8, 6))
correlacion = df[cols].corr()
sns.heatmap(correlacion,
            annot=True,          # muestra los números
            fmt='.2f',          # 2 decimales
            cmap='coolwarm',    # azul=negativo, rojo=positivo
            center=0,
            ax=ax)
ax.set_title('Correlación entre variables eléctricas')
plt.tight_layout()
plt.show()
```

```
In [25]: # Gráfico 5 – Comparación de submedidores (boxplot)
sub = df[['Sub_metering_1', 'Sub_metering_2', 'Sub_metering_3']].copy()
sub_melted = sub.melt(var_name='Zona', value_name='Consumo_Wh')

fig, ax = plt.subplots()
sns.boxplot(data=sub_melted, x='Zona', y='Consumo_Wh', ax=ax, legend=False)
ax.set_title('Distribución de consumo por zona del hogar')
ax.set_xlabel('Zona')
ax.set_ylabel('Consumo (Wh)')
plt.tight_layout()
plt.show()
```




Con lo que tienes hasta aquí, construye estos dos gráficos adicionales por tu cuenta:

Ejercicio A: Consumo promedio por día de la semana. Pista: `df.index.dayofweek` te da el número del día (0=lunes, 6=domingo). Usa un barplot de Seaborn.

Ejercicio B: Serie temporal del voltaje durante el mes de febrero 2007 (`df['Voltage']['2007-02']`). Usa `ax.plot()` de Matplotlib. Observa: ¿el voltaje es estable o fluctúa mucho?


```
In [26]: # Gráfico 3 – Consumo promedio por hora del día
df['día'] = df.index.dayofweek # Cambié a dayofweek para ver el consumo por día de la semana
consumo_por_dia = df.groupby('día')['Global_active_power'].mean().reset_index()

fig, ax = plt.subplots()
sns.barplot(data=consumo_por_dia,
            x='día', y='Global_active_power',
            color='#2E86AB', ax=ax)
ax.set_title('Consumo promedio por día de la semana')
ax.set_xlabel('Día de la semana (0=lunes, 6=domingo)')
ax.set_ylabel('Potencia activa promedio (kW)')
plt.tight_layout()
plt.show()
```



```
In [27]: # Gráfico 1 – Consumo activo a lo largo del tiempo (muestra 1 semana)
mes = df['Voltage']['2007-02']

fig, ax = plt.subplots()
ax.plot(mes, color='#2E86AB', linewidth=0.8, alpha=0.9)
ax.set_title('Consumo eléctrico activo – febrero 2007')
ax.set_xlabel('Fecha')
ax.set_ylabel('Potencia activa (kW)')
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```



El comportamiento del voltaje tiene una forma sinusoidal de alta frecuencia lo que corresponde a la realidad porque las mediciones del dataset son de parámetros eléctricos de un hogar el cual se alimenta con corriente alterna. Además, se notan cinco valles con voltajes menores a 230 y uno con voltaje menor a 225, lo cual no es una caída considerable pero sí se aleja del rango usual en el cual se encuentra el voltaje: 230 - 250 V.